

## TAREA #1 PROGRAMACIÓN NO LINEAL

① Realizar los ejercicios 2.7 y 2.8 del texto guía.

2.7) Suppose that  $f(x) = x^T Q x$ , where  $Q$  is an  $n \times n$  symmetric positive semidefinite matrix. Show using the definition (1.4) that  $f(x)$  is convex on the domain  $\mathbb{R}^n$ .

HINT: It may be convenient to prove the following equivalent inequality:

$$f(y + \alpha(x - y)) - \alpha f(x) - (1 - \alpha)f(y) \leq 0$$

for all  $\alpha \in [0, 1]$  and all  $x, y \in \mathbb{R}^n$

Dem: Supongamos que  $f(x) = x^T Q x$ , donde  $Q$  es una matriz semidefinida positiva simétrica y  $n \times n$ .

Veamos que,  $f(x)$  es convexa en el dominio  $\mathbb{R}^n$

De la hipótesis de que  $Q$  es semidefinida positiva, tenemos que

$$P^T Q P \geq 0 \quad \forall P \in \mathbb{R}^n$$

De donde particularmente,

$$\begin{aligned} f(x) &= x^T Q x \geq 0 \\ \therefore f(x) &\geq 0 \end{aligned}$$

Ahora, por definición de función convexa, deseamos ver que  $\forall x, y \in \mathbb{R}^n$ ,  $\alpha \in [0, 1]$

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$$

$$\Leftrightarrow f(y + \alpha(x - y)) \leq \alpha f(x) + (1 - \alpha)f(y)$$

$$\Leftrightarrow f(y + \alpha(x - y)) - \alpha f(x) - (1 - \alpha)f(y) \leq 0 \quad (1)$$

Que es justamente la pista de demostración brindada.

Aplicamos la definición de  $F(x)$  en (1), tenemos:

$$\begin{aligned}
 f(y + \alpha(x-y)) - \alpha f(x) - (1-\alpha)f(y) &= \\
 &= [y + \alpha(x-y)]^T Q [y + \alpha(x-y)] - \alpha x^T Q x - (1-\alpha)y^T Q y \\
 &= (y^T + \alpha(x-y)^T) Q (y + \alpha(x-y)) - \alpha x^T Q x - (1-\alpha)y^T Q y \\
 &= (y^T + \alpha x^T - \alpha y^T) Q (y + \alpha x - \alpha y) - \alpha x^T Q x - (1-\alpha)y^T Q y \\
 &= (\alpha x^T + (1-\alpha)y^T) Q (\alpha x + (1-\alpha)y) - \alpha x^T Q x - (1-\alpha)y^T Q y \\
 &= \alpha^2 x^T Q x + \alpha(1-\alpha)x^T Q y + \alpha(1-\alpha)y^T Q x + (1-\alpha)^2 y^T Q y \\
 &\quad - \alpha x^T Q x - (1-\alpha)y^T Q y \\
 &= (\alpha^2 - \alpha)x^T Q x + [(1-\alpha)^2 - (1-\alpha)]y^T Q y + \alpha(1-\alpha)x^T Q y \\
 &\quad + \alpha(1-\alpha)y^T Q x \\
 &= \alpha(\alpha-1)x^T Q x + [1-2\alpha+\alpha^2-1+\alpha]y^T Q y \\
 &\quad + \alpha(1-\alpha)x^T Q y + \alpha(1-\alpha)y^T Q x \\
 &= \alpha(\alpha-1)x^T Q x + \alpha(\alpha-1)y^T Q y + \alpha(1-\alpha)x^T Q y \\
 &\quad + \alpha(1-\alpha)y^T Q x \\
 &= \alpha(\alpha-1)[x^T Q x + y^T Q y - x^T Q y - y^T Q x] \\
 &= \alpha(\alpha-1)(x-y)^T Q (x-y)
 \end{aligned}$$

Ahora, como  $\alpha \in [0,1]$ ,  $(\alpha-1) \leq 0$ , y como  $Q$  es semidefinida positiva,  $(x-y)^T Q (x-y) \geq 0$ .  
Así, tenemos

$$\alpha(\alpha-1)(x-y)^T Q (x-y) \leq 0$$

Así,

$$f(y + \alpha(x-y)) - \alpha f(x) - (1-\alpha)f(y) \leq 0$$

y por tanto,  $F(x)$  es convexa en el dominio  $\mathbb{R}^n$ .

2.8) Suppose that  $F$  is a convex function.  
Show that the set of global minimizers  
of  $F$  is a convex set.

Dem: Sea  $F$  una función convexa. Veamos que  
el conjunto de minimizadores globales de  $F$   
es un conjunto convexo.

Sean  $x_1, x_2$  minimizadores globales de  $F$ ,  
queremos ver que para  $x_1, x_2$  en el conjunto  
de minimizadores globales y  $\alpha \in [0, 1]$ , tenemos

$\alpha x_1 + (1 - \alpha)x_2$  es minimizador global

Ahora, por hipótesis tenemos dos cosas;

(1)  $F(x_1) = F(x_2) \leq F(x)$ ,  $\forall x \in \Omega \Rightarrow x_1, x_2$  min glob

(2)  $F(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha F(x_1) + (1 - \alpha)F(x_2)$ ,  $\forall x_1, x_2 \in \Omega$   
 $\alpha \in [0, 1]$

(Pues  $F$  es convexa)

De (2) tenemos que,

$$F(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha F(x_1) + (1 - \alpha)F(x_2)$$

$$[\text{De (1)}] \leq \alpha F(x) + (1 - \alpha)F(x)$$

$$= \alpha F(x) + F(x) - \alpha F(x) = F(x)$$

$$\text{Así, } F(\alpha x_1 + (1 - \alpha)x_2) \leq F(x), \alpha \in [0, 1]$$

De donde  $\alpha x_1 + (1 - \alpha)x_2$  es un minimizador global  
y por tanto, tenemos que el conjunto de  
minimizadores globales es convexo //



## ② ANÁLISIS DE EJEMPLOS

- $f(x) = \cos(x + \pi/4) \Rightarrow \text{Ej: 1-4}$

Logramos ver con gran claridad la importancia de la elección de valores como  $P$  y  $\alpha$ , valores importantes para la elección del Paso

Primero, con  $P=0,75$  y  $\alpha=5,0$  (Ej 1), vemos un avance más discreto, con avance horizontal más grande pero menor avance al mínimo buscado

Con  $P=0,5$  y  $\alpha=5,0$  (Ej 2), vemos un avance mucho más precipitado, pues en una iteración se recorta mucho más el valor de  $\alpha$  en la multiplicación  $p \cdot \alpha$ , lo cual nos acerca mucho más rápido al mínimo

Para  $P=0,5$ ,  $\alpha=2,0$  (Ej 3) y  $P=0,75$ ,  $\alpha=2,0$  (Ej 4) obtenemos un resultado muy parecido, en algo que parece ser un "equilibrio" o ser valores que caen en la misma zona de condición cumplida, por lo que no hay muchas iteraciones, nuevamente se acerca bastante al punto mínimo.

- $f(x) = 100(x_1 - x_0^2)^2 + (1 - x_0^2) \Rightarrow \text{Ej: 5-8}$

Tal como en el anterior, vemos como la elección de las dos constantes  $P, \alpha$ , juegan un papel fundamental en la decisión del tamaño de Paso, siendo  $P=0,75$ ,  $\alpha=3,0$  (Ej 7) la elección que nos acerca con un Paso más grande en comparación a los valores testeados en los otros ejemplos

Es claro como con las elecciones de ciertas constantes restringimos los resultados y el # de iteraciones de un algoritmo que usa la evaluación y aprobación de dos condiciones (Wolfe y Armijo) con el fin de encontrar un tamaño de Paso conveniente según la dirección y los valores de posición brindados.

### ③ IMPORTANCIA DE LA CONDICIÓN 3.14

$$\sum_{k \geq 0} \cos^2 \theta_k \|\nabla F_k\|^2 < \infty$$

$\downarrow$   
 $<$

Sabiendo que  $\cos \theta_k$  relaciona el ángulo entre la dirección tomada y la dirección más decreciente, la condición 3.14 sin duda alguna nos da indicios de una convergencia del método, pues implica que al infinito esta relación se vuelve cero, es decir

$$\cos^2 \theta_k \|\nabla F_k\|^2 \rightarrow 0$$

Como es fácil notar, la condición 3.14 relaciona dos cosas, el ángulo entre la dirección hacia donde nos dirigimos y la dirección más decreciente y el tamaño del vector gradiente, es decir, el tamaño del vector de la dirección más decreciente, y el hecho de que tienda a cero nos dice que nuestras elecciones de direcciones se van volviendo más y más precisas ( $\cos \rightarrow 0$ ) o que llegamos el punto en que independiente de la dirección, estamos muy cerca o llegamos a un minimizador local, por lo que no sería necesario más movimiento ( $\nabla F_k \rightarrow 0$ ).

En conclusión, la condición 3.14 juega un papel importante, pues nos ayuda a derivar y/o deducir una convergencia global de los algoritmos de búsqueda lineal, haciendo comparaciones con el decrecimiento ideal.